

Decomposição Espectro-temporal de Extremos do Pixel Purity Index Compatíveis com Vegetação Fotossinteticamente Ativa em Quatro Classes do TerraClass Amazônia

Rodrigo L. Brito Neto¹, Débora T. Giancola¹, Abner Ernâni dos Anjos¹, Bruna H. Sacramento¹, Erison C. S. Monteiro¹, Jadson Q. da Silva¹, Mayara Teodoro¹

¹ Instituto Nacional de Pesquisa Espacial
Caixa Postal 515 – 12.227-010 – São José dos Campos – SP – Brazil

britoneterl@gmail.com, debora.giancola@inpe.br,
abiner.anjos@gmail.com, bruna.sacramento@inpe.br,
erison.monteiro@inpe.br, jadson.qds@gmail.com,
lmayarateodoro@gmail.com

Abstract. *Vegetation classes in the Amazon share overlapping spectral responses, with seasonal and irregular variation mixed within a single reflectance trajectory, so it remains unclear which spectral domains concentrate consistent annual recurrence. Seasonal strength was assessed in Pixel Purity Index (PPI) extremes from four permanent TerraClass classes over 184 Sentinel-2 time points (2017–2024); 658 of 736 class–date combinations retained an extreme compatible with active vegetation. Robust Seasonal-Trend decomposition using Loess (STL) revealed class- and band-specific annual patterns, with the clearest recurrence in red-edge and near-infrared bands.*

Resumo. *Classes de vegetação na Amazônia apresentam respostas espectrais sobrepostas, com variação sazonal e irregular misturadas em uma mesma trajetória, e permanece pouco esclarecido quais domínios concentram recorrência anual consistente. A força sazonal foi avaliada em extremos do Pixel Purity Index (PPI) de quatro classes permanentes do TerraClass em 184 pontos no tempo Sentinel-2 (2017–2024); 658 de 736 combinações classe–data retiveram um extremo compatível com vegetação ativa. A decomposição sazonal e de tendência por Loess (STL) robusta revelou padrões anuais específicos por classe e banda, com recorrência mais nítida no red edge e infravermelho próximo.*

1. Introdução

Pixels multiespectrais ocupam um espaço de mistura, representação em que o sinal do pixel reflete a proporção dos alvos que o compõem, delimitado por vegetação, substratos e superfícies escuras [Small and Sousa 2022]. Modelos de mistura estimam essas frações [Shimabukuro and Smith 1991], enquanto o PPI (*Pixel Purity Index*) [Boardman et al. 1995] identifica observações extremas no espaço espectral de forma não supervisionada.

A reflectância da vegetação amazônica varia em resposta à estrutura do dossel, à iluminação e à fenologia [Galvão et al. 2024]. Como essas fontes se sobrepõem em uma mesma trajetória, a comparação direta entre bandas não separa o ciclo anual recorrente das flutuações irregulares. A decomposição explicita essa separação e quantifica, por

banda, a fração da variabilidade atribuível ao ciclo anual: domínios com sazonalidade estável tendem a ser âncoras temporais mais confiáveis em modelos de mistura e em classificadores de séries temporais. Neste trabalho, investigou-se como a predominância da variação sazonal sobre a variação irregular difere entre domínios espectrais nas trajetórias dos extremos PPI de quatro classes do TerraClass. Cada observação corresponde ao candidato de maior escore compatível com vegetação fotossinteticamente ativa, rótulo estritamente espectral que não constitui medida direta de fotossíntese, abundância ou fenologia local.

2. Materiais e Métodos

Analísaram-se núcleos homogêneos de 3×3 pixels da mesma classe do TerraClass em 2016, 2018, 2020, 2022 e 2024 [de Almeida et al. 2016], nas classes 02 (Vegetação Natural Florestal Secundária), 09 (Silvicultura), 10 (Pastagem Arbustiva/Arbórea) e 11 (Pastagem Herbácea). A classe 01 (Vegetação Natural Florestal Primária) foi excluída por não atingir o limiar de permanência de 80%. Não se realizou validação independente dos mapas.

Uma malha sistemática em Brazil Polyconic (EPSG:5880) selecionou 1.000 pontos por classe. O limite amostral foi operacional. O *Web Time Series Service* do *Brazil Data Cube* forneceu 184 pontos no tempo da coleção S2-16D-2 entre 2017 e 2024, nas bandas B02–B08, B8A, B11 e B12 [Vinhas et al. 2017, Gomes et al. 2024]. Excluíram-se valores não finitos e observações reprovadas pelos filtros CLEAROB (contagem de observações livres de nuvem, sombra, neve ou dado ausente) e *Scene Classification Layer* (máscara por pixel que sinaliza nuvem, sombra e baixa confiabilidade).

No PPI, as reflectâncias foram centralizadas pela média e projetadas em 10.000 direções unitárias aleatórias. Máximos e mínimos de cada projeção receberam votos, formando um conjunto ordenado. Retiveram-se até quatro candidatos por combinação classe–data, separados por ângulo espectral mínimo de 2° pelo *Spectral Angle Mapper* (SAM) [Kruse et al. 1993].

$$\text{PPI}(i) = \sum_{k=1}^{10000} \left[1 \left\{ i = \arg \max_j z_j^T r_k \right\} + 1 \left\{ i = \arg \min_j z_j^T r_k \right\} \right] \quad (1)$$

Em que, na Equação 1: i é o pixel avaliado; j , cada pixel válido; k , a direção; z_j , o espectro centralizado; r_k , o vetor unitário; $1\{\cdot\}$, a função indicadora.

As bandas foram agrupadas em quatro domínios: visível (VIS), B02–B04; *red edge*, B05–B07; infravermelho próximo (NIR), B08 e B8A; e infravermelho de ondas curtas (SWIR), B11 e B12. Cada domínio foi representado pela mediana de suas bandas.

A inspeção considerou absorção no visível, elevação no *red edge*, maior reflectância no NIR e coerência no SWIR.

A decomposição STL robusta separou cada trajetória em tendência, componente sazonal anual e resíduo [Cleveland et al. 1990]. Adotaram-se período 23 e janelas sazonal, de tendência e passa-baixa de 7, 45 e 25. A interpolação linear foi aplicada somente na entrada da STL, enquanto as métricas utilizaram as datas originalmente observadas.

$$Y_{c,b,t} = T_{c,b,t} + S_{c,b,t} + R_{c,b,t} \quad (2)$$

$$F_S = \max \left(0, 1 - \frac{\text{Var}(R)}{\text{Var}(S+R)} \right) \quad (3)$$

Em que, nas Equações 2 e 3: $Y_{c,b,t}$ é a reflectância da classe c , banda b e data t ; T , a componente de baixa frequência; S , a componente anual recorrente; R , o resíduo; F_s , a força sazonal; e Var é a variância. F_s varia de 0 a 1, com valores altos indicando resíduo pequeno frente a $S + R$ [Wang et al. 2006].

3. Resultados e Discussão

Das 736 combinações classe–data, 658 retiveram um extremo compatível com vegetação ativa. As classes Vegetação Secundária, Silvicultura, Pastagem Arbustiva/Arbórea e Pastagem Herbácea contribuíram, respectivamente, com 160, 173, 165 e 160 datas. As medianas de F_s foram, para VIS, *red edge*, NIR e SWIR foram, respectivamente: 0,046, 0,435, 0,494 e 0,143, Vegetação Secundária; 0,175, 0,331, 0,350 e 0,318, Silvicultura; 0,242, 0,481, 0,439 e 0,343, Pastagem Arbustiva/Arbórea; e 0,295, 0,551, 0,583 e 0,010, Pastagem Herbácea.

Na Vegetação Secundária (Figura 1), a recorrência concentrou-se no *red edge* e no NIR, enquanto VIS e SWIR tiveram maior contribuição residual. A Silvicultura mostrou distribuição mais equilibrada entre *red edge*, NIR e SWIR, e na Pastagem Arbustiva/Arbórea os ciclos foram mais evidentes entre B06 e B8A. A Pastagem Herbácea apresentou o maior contraste: *red edge* e NIR alcançaram as maiores forças sazonais do conjunto, enquanto o SWIR teve F_s mediana de 0,010, dominada por pulsos irregulares cujos mecanismos a decomposição não isola.

Em conjunto, *red edge* e NIR foram as regiões mais consistentes para a recorrência anual dos extremos PPI, e o contraste entre VIS e SWIR diferenciou a classe herbácea daquelas com componente arbóreo ou arbustivo. Entretanto, esse resultado constitui evidência espectro-temporal preliminar, e não demonstração direta da presença de biomassa lenhosa.

A decomposição aditiva de séries de satélite em tendência, componente sazonal e resíduo é consolidada em sensoriamento remoto, sobretudo em detecção de mudanças e de alterações fenológicas [Verbesselt et al. 2010], e a STL já foi comparada a BFAST e a wavelets em séries de índices de vegetação [Ben Abbes et al. 2018]. Esses trabalhos visam rupturas e tendências, não a força sazonal por domínio. A métrica F_s provém da literatura de caracterização de séries temporais [Wang et al. 2006] e, até onde foi possível verificar, permanece pouco explorada em sensoriamento remoto, o que limita a comparação direta dos valores obtidos.

A posição dos extremos não foi mantida entre datas (distâncias medianas de 222 a 774 km), de modo que as trajetórias concatenam localizações distintas. Os diagnósticos de sensibilidade preservaram a ordenação dos domínios.




Figure 1. Componentes STL dos extremos PPI: Vegetação Secundária, Silvicultura, Pastagem Arbustiva/Arbórea e Pastagem Herbácea.

4. Conclusões

A recorrência anual dos extremos *Pixel Purity Index* concentrou-se no *red edge* e no infravermelho próximo nas quatro classes, com contraste mais intenso na Pastagem

Herbácea, que combinou elevada força sazonal no *red edge* e NIR e sinal praticamente ausente no SWIR. Os resultados são preliminares e condicionais aos pixels válidos. Estudos futuros devem controlar disponibilidade temporal, dependência espacial, iluminação e substituição espacial dos extremos.

5. References

- Ben Abbes, A., Bounouh, O., Farah, I. R., de Jong, R., and Martínez, B. (2018). Comparative study of three satellite image time-series decomposition methods for vegetation change detection. *European Journal of Remote Sensing*, 51(1):607--615.
- Boardman, J. W., Kruse, F. A., and Green, R. O. (1995). Mapping target signatures via partial unmixing of AVIRIS data. In *Summaries of the Fifth Annual JPL Airborne Earth Science Workshop, Volume 1: AVIRIS Workshop*, pages 23--26, Pasadena, California. Jet Propulsion Laboratory.
- Cleveland, R. B., Cleveland, W. S., McRae, J. E., and Terpenning, I. (1990). STL: A seasonal-trend decomposition procedure based on loess. *Journal of Official Statistics*, 6(1):3--73.
- de Almeida, C. A., Coutinho, A. C., Esquerdo, J. C. D. M., Adami, M., Venturieri, A., Diniz, C. G., Dessay, N., Durieux, L., and Gomes, A. R. (2016). High spatial resolution land use and land cover mapping of the brazilian legal amazon in 2008 using Landsat-5/TM and MODIS data. *Acta Amazonica*, 46(3):291--302.
- Galvão, L. S., Petri, C. A., and Dalagnol, R. (2024). Coupled effects of solar illumination and phenology on vegetation index determination: An analysis over the amazonian forests using the SuperDove satellite constellation. *GIScience & Remote Sensing*, 61(1):2290354.
- Gomes, V. C. F., Queiroz, G. R., Ferreira, K. R., Pebesma, E., and Barbosa, C. C. F. (2024). Brazil data cube workflow engine: A tool for big earth observation data processing. *International Journal of Digital Earth*, 17(1):2313099.
- Kruse, F. A., Lefkoff, A. B., Boardman, J. W., Heidebrecht, K. B., Shapiro, A. T., Barloon, P. J., and Goetz, A. F. H. (1993). The spectral image processing system (SIPS)—interactive visualization and analysis of imaging spectrometer data. *Remote Sensing of Environment*, 44(2-3):145--163.
- Shimabukuro, Y. E. and Smith, J. A. (1991). The least-squares mixing models to generate fraction images derived from remote sensing multispectral data. *IEEE Transactions on Geoscience and Remote Sensing*, 29(1):16--20.
- Small, C. and Sousa, D. (2022). The Sentinel 2 MSI spectral mixing space. *Remote Sensing*, 14(22):5748.
- Verbesselt, J., Hyndman, R., Newnham, G., and Culvenor, D. (2010). Detecting trend and seasonal changes in satellite image time series. *Remote Sensing of Environment*, 114(1):106--115.
- Vinhas, L., de Queiroz, G. R., Ferreira, K. R., and Câmara, G. (2017). Web services for big earth observation data. *Revista Brasileira de Cartografia*, 69(5).
- Wang, X. C., Smith, K. A., and Hyndman, R. J. (2006). Characteristic-based clustering for time series data. *Data Mining and Knowledge Discovery*, 13(3):335--364.